

INCERTITUDE

8INF878 - Intelligence Artificielle

Kévin Bouchard

Ordre du jour

2

- Incertitude
- Probabilité
- Syntaxe et sémantique
- Inférence
- Indépendance et règle de Bayes

Incertitude

3

- Supposons A_t = Se rendre à l'aéroport t minutes avant le vol.
- Est-ce que A_t m'amènera à temps?

- Problèmes:
 - 1) Partiellement observable (route, autos, etc.)
 - 2) Bruits dans les capteurs
 - 3) Incertitude dans la réalisation des actions (crevaision, etc.)
 - 4) Complexité importante en ce qui attrait à la modélisation et à la prédiction du trafic

Incertitude (suite)

4

□ Une approche purement logique

1) Risque de mensonge: « A_{25} va me rendre à temps » ou encore...

2) conduit à des conclusions qui sont trop faibles pour la prise de décision:

« A_{25} va m'amener à temps s'il n'y a pas d'accident sur le pont et qu'il ne pleut pas et que mes pneus restent intacts, etc. »

(A_{1224} pourrait raisonnablement être décrit par va me rendre à temps, mais je devrais passer la nuit à l'aéroport ...)

Méthodes pour gérer l'incertitude

5

- Logique non monotone:
 - ▣ Assumons que ma voiture n'a pas de crevaison
 - ▣ Assumons que A_{25} fonctionne sauf si contredit par une évidence
- Le problème est qu'il est difficile de déterminer quelles hypothèses sont **raisonnables** et comment gérer les **contradictions**
- Règles avec facteur arbitraire (fudge factor):
$$A_{25} \mapsto_{0.3} AtAirportOnTime$$
$$Sprinkler \mapsto_{0.99} WetGrass$$
$$WetGrass \mapsto_{0.7} Rain$$
- Problème avec les combinaisons (arroseur cause la pluie?)

Méthodes pour gérer l'incertitude

6

- Probabilité
 - Selon les évidences disponibles
 - A_{25} m'amènera à temps avec une probabilité de 0.04
- Cardamo (1565) théorie des jeux de hasard
- Attention! La logique floue gère les degrés de vérités, PAS l'incertitude
 - E.g.: Le ciel est bleu est vrai à 0.8

Probabilités

7

- Les assertions probabilistes résumes les effets de
 - ▣ La paresse: incapable d'énumérer les exceptions, les qualifications, etc.
 - ▣ L'ignorance: l'absence de faits pertinents, les conditions initiales, etc.

- Probabilités Bayésienne:
 - ▣ Les probabilités s'appliquent sur les connaissances d'une personne sur les connaissances
 - ▣ E.g.: $P(A_{25} | \text{pas d'accidents}) = 0.06$

Probabilités

8

- Ce ne sont pas les revendications d'une «tendance probabiliste» dans la situation actuelle
 - ▣ Mais! pourraient être tirés des expériences passées de situations similaires

- Les probabilités de propositions changent avec de nouvelles preuves:
 - ▣ E.g.: $P(A_{25} | \text{aucun accidents signalé}, 5h) = 0.15$
 - ▣ Analogue à l'état de l'implication logique $KB \models \alpha$, pas la vérité

Prendre des décisions dans l'incertitude

9

- Supposons que je crois ceci:

$$P(A_{25} \text{ m'amène à temps} | \dots) = 0.04$$

$$P(A_{90} \text{ m'amène à temps} | \dots) = 0.7$$

$$P(A_{120} \text{ m'amène à temps} | \dots) = 0.95$$

$$P(A_{1440} \text{ m'amène à temps} | \dots) = 0.99$$

- Quelle action choisir? Dépend de mes préférences sur manquer un vol vs vivre à l'aéroport
- **Decision theory = utility theory + probability theory**
 - ▣ Rationalité=Maximum Expected Utility!!!!

```
function DT-AGENT(percept) returns an action
  persistent: belief_state, probabilistic beliefs about the current state of the world
               action, the agent's action

  update belief_state based on action and percept
  calculate outcome probabilities for actions,
    given action descriptions and current belief_state
  select action with highest expected utility
    given probabilities of outcomes and utility information
  return action
```

10

Bases

Bases des probabilités

11

- Commençons avec l'ensemble Ω , l'espace échantillon
 - ▣ E.g.: 6 possibilités au roulement d'un dé
 - ▣ $\omega \in \Omega$ est un point d'échantillon ou un événement atomique
- Un espace de probabilités ou un modèle de probabilités est un espace échantillon avec un assignement $P(\omega) \forall \omega \in \Omega$
 - ▣ $0 \leq P(\omega) \leq 1$
 - ▣ $\sum_{\omega} P(\omega) = 1$
- E.g.: $P(1) = P(2) = P(3) = P(4) = P(5) = P(6) = 1/6$
- Un événement A est n'importe quel sous ensemble de Ω
 - ▣ $P(A) = \sum_{\{\omega \in A\}} P(\omega)$
- E.g.: $P(\text{dé} < 4) = P(1) + P(2) + P(3) = 1/2$

Variables aléatoires

12

- Une variable aléatoire est une fonction d'un ensemble de points échantillons
 - ▣ E.g. \mathbb{R} ou encore les booléens
 - ▣ E.g. $\text{impair}(1) = \text{Vrai}$
- P induit une distribution de probabilités pour toute variable aléatoire X :
 - ▣ $P(X = x_i) = \sum_{\{\omega: X(\omega)=x_i\}} P(\omega)$

$$P(\text{Impair} = \text{vrai}) = P(1) + P(3) + P(5) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

Propositions

13

- Supposons les variables booléennes A et B :
 - ▣ Évènement $a = \{\omega | A(\omega) = Vrai\}$
 - ▣ Évènement $\neg a = \{\omega | A(\omega) = Faux\}$
 - ▣ Évènement $a \wedge b = \{\omega | A(\omega) = Vrai \wedge B(\omega) = Vrai\}$

- Souvent dans les applications en IA, l'ensemble des points échantillons (**sample points**) sont définis par les valeurs d'un ensemble de variables aléatoires
 - ▣ I.e.: l'espace échantillon est le produit cartésien des plages de valeurs des variables

Propositions (suite)

14

- Avec les variables booléennes:
 - ▣ Sample points=modèle de logique propositionnelle
 - ▣ E.g.: $A = \text{vrai}, B = \text{faux}$ ou $a \wedge \neg b$


- Proposition = disjonction d'évènements atomiques pour laquelle celle-ci est vraie
 - ▣ E.g.: $(a \vee b) \equiv (\neg a \wedge b) \vee (a \wedge \neg b) \vee (a \wedge b) \Rightarrow$
 $P(a \vee b) = P(\neg a \wedge b) + P(a \wedge \neg b) + P(a \wedge b)$

Pourquoi utiliser les probabilités?

15

- Les définitions impliquent que certains événements logiquement liés doivent avoir des probabilités liées
- E.g.: $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$

True



- Finetti (1931): un agent qui mise selon des probabilités qui transgresse ces axiomes peut être forcé de miser de manière à perdre de l'argent indépendamment du résultat.

16

Probabilités 101

Syntaxes des propositions

17

- Variables aléatoires **propositionnelles** ou **booléennes**
 - ▣ E.g.: *Carie* (Ai-je une carie?)
 - ▣ *Carie = vrai* est une proposition
- Variables aléatoires **discrètes** (finies ou infinies)
 - ▣ E.g.: *Température* est dans $\{ensoleillée, pluvieuse, neigeuse, nuageuse\}$
 - ▣ *Température = pluvieuse* est une proposition
 - ▣ Les valeurs doivent être exhaustive et mutuellement exclusive
- Variables aléatoires **continues** (bornées ou non)
 - ▣ E.g: *Température* = 21.3
- Combinaisons booléennes arbitraires de propositions de base

Probabilité antérieure


18

- Les probabilités **antérieures** ou **inconditionnelles** des propositions correspondent à la croyance avant l'arrivée de toute (nouvelle) évidence
 - ▣ E.g.: $P(\text{Carie} = \text{true}) = 0.1$ et
 - ▣ $P(\text{Température} = \text{neigeuse}) = 0.72$
- Une distribution de probabilités donne des valeurs pour toutes les affectations possibles:
 - ▣ $P(\text{Température}) = \langle 0.08, 0.1, 0.72, 0.1 \rangle$
 - ▣ Normalisée -> somme = 1

Probabilités pour variables continues

19

- La distribution est exprimée comme une fonction paramétrable de valeurs:
 - ▣ $P(X = x) = U[18C, 26C](x)$
 - ▣ →Densité uniforme entre 18 et 26




- Ici, P est une **densité**; son intégrale est 1
- $P(X = 20.5) = 0.125$ signifie

$$\lim_{dx \rightarrow 0} \frac{P(20.5 \leq X \leq 20.5 + dx)}{dx} = 0.125$$

Densité Gaussienne

20

$$\square P(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2}$$



Probabilité antérieure (suite)

21

- La **distribution de probabilités conjointes** pour un ensembles de variables aléatoires donne les probabilités de chacun des évènements atomiques
 - ▣ I.e.: chaque point échantillon
 - ▣ $P(\text{Température}, \text{Carie}) = 4 \times 2$ matrice de valeurs:

Température	Neigeuse	Pluvieuse	Ensoleillée	nuageuse
Carie=Vrai	0.144	0.02	0.016	0.02
Carie=Faux	0.576	0.08	0.064	0.08

- Chaque question à propos d'un domaine peut être répondu par celle-ci puisque chaque évènement est la somme de points échantillons

Probabilité conditionnelle

22

- Probabilités conditionnelles ou à posteriori
 - E.g.: $P(\text{carie}|\text{maldedent}) = 0.8$
 - i.e.: Supposons que je sais $\text{MalDeDent}=V$, que je n'ai pas d'autres informations, $\text{Carie}=Vrai$ avec 0.8 de probabilité
 - PAS → Si MalDeDent , 80% de chance de Carie
- Si nous savons plus, par ex. que Carie est vrai
 - $P(\text{carie}|\text{maldedent}, \text{carie}) = 1$

Probabilité conditionnelle

23

- Notons que les connaissances moins spécifiques **demeurent valides** après l'obtention de nouvelles informations, mais ne sont pas toujours utiles
- Elles peuvent donc être simplifiées!
 - $P(\text{carie}|\text{mal de dent}, \text{le sudoku est complet}) = P(\text{carie}|\text{mal de dent}) = 0.8$
- Ce type d'inférence, sanctionnée par la connaissance du domaine, est crucial

Probabilité conditionnelle

24

- Définition:

$$P(a|b) = \frac{P(a \wedge b)}{P(b)} \text{ if } P(b) \neq 0$$

- La règle du produit donne une formulation alternative:

$$P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$$

- Une version générale tient pour distributions entières
 - E.g.: $P(\text{Température}, \text{Carie}) = P(\text{Température}|\text{Carie})P(\text{Carie})$
 - (voir comme un ensemble 4X2 d'équations, pas une matrice)

Probabilité conditionnelle

25

- La **règle de chaînage** est dérivée de l'application successive de la règle du produit:

$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1, \dots, X_{n-1})P(X_n|X_1, \dots, X_{n-1}) \\ &= P(X_1, \dots, X_{n-2})P(X_{n-1}|X_1, \dots, X_{n-2})P(X_n|X_1, \dots, X_{n-1}) \\ &\quad = \dots \\ &= \prod_i^n P(X_i|X_1, \dots, X_{i-1}) \end{aligned}$$

Inférence par l'énumération

26

- Commençons avec la distribution conjointe:

	MalDeDent		¬MalDeDent	
	Prise	¬Prise	Prise	¬Prise
Carie	.108	.012	.072	.008
¬Carie	.016	.064	.144	.576

- Pour toute proposition ϕ , la somme des évènements atomiques est:

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$$

Inférence par l'énumération

27

- Commençons avec la distribution conjointe:

	MalDeDent		¬MalDeDent	
	Prise	¬Prise	Prise	¬Prise
Carie	.108	.012	.072	.008
¬Carie	.016	.064	.144	.576

- Pour toute proposition ϕ , la somme des évènements atomiques est:

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$$

$$P(\text{maldedent}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$$

Inférence par l'énumération

28

- Commençons avec la distribution conjointe:

	MalDeDent		¬MalDeDent	
	Prise	¬Prise	Prise	¬Prise
Carie	.108	.012	.072	.008
¬Carie	.016	.064	.144	.576

- Pour toute proposition ϕ , la somme des évènements atomiques est:

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$$

$$P(\text{carie} \vee \text{maldedent})$$

$$= 0.108 + 0.012 + 0.016 + 0.064 + 0.072 + 0.008 = 0.28$$

Inférence par l'énumération

29

- Commençons avec la distribution conjointe:

	MalDeDent		¬MalDeDent	
	Prise	¬Prise	Prise	¬Prise
Carie	.108	.012	.072	.008
¬Carie	.016	.064	.144	.576

- Pour toute proposition ϕ , la somme des évènements atomiques est:

$$P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$$
$$P(\neg carie | maldedent) = \frac{P(\neg carie \wedge maldedent)}{P(maldedent)}$$
$$= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4$$

Inférence par l'énumération

30

	MalDeDent		¬MalDeDent	
	Prise	¬Prise	Prise	¬Prise
Carie	.108	.012	.072	.008
¬Carie	.016	.064	.144	.576

- Le dénominateur peut être considéré comme une constante de normalisation α

$$\begin{aligned}P(\text{Carie}|\text{maldedent}) &= \alpha P(\text{Carie}, \text{maldedent}) \\&= \alpha [P(\text{Carie}, \text{maldedent}, \text{prise}) + P(\text{Carie}, \text{maldedent}, \neg \text{prise})] \\&= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] \\&= \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle\end{aligned}$$

- **Idée générale:** Calculer la distribution sur la variable interrogée en fixant les **variables d'évidences** et en additionnant les **variables cachées**

Inférence par l'énumération

31

- Supposons X l'ensemble des variables.
- Nous voulons la distribution conjointe à postériori des variables interrogeables Y
 - ▣ Étant donnée les valeurs spécifiques e pour les variables d'évidences E
- Supposons les variables cachées $H = X - Y - E$
- La sommation requise des entrées conjointes se fait en additionnant les variables cachées:

$$P(Y|E = e) = \alpha P(Y, E = e) = \alpha \sum_h P(Y, E = e, H = h)$$

Inférence par l'énumération

32

- Les termes dans la somme sont des entrées conjointes puisque Y , E et H ensemble épuise les variables aléatoires X
- Problème évident:
 1. Complexité temporelle en pire cas $O(d^n)$ où d est la plus grande arité
 2. Complexité spatiale en pire cas $O(d^n)$ pour l'enregistrement de la distribution
 3. Comment trouver les nombres pour $O(d^n)$ entrées?

33

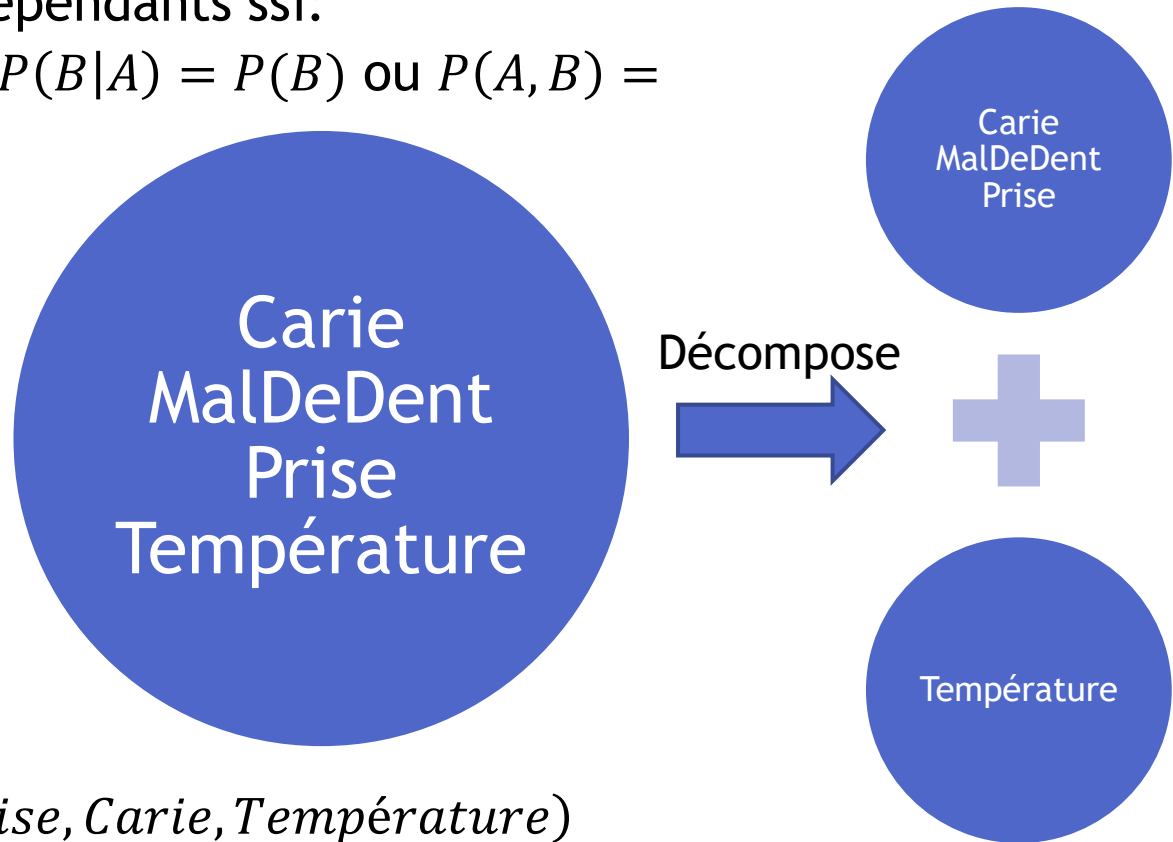
Indépendance

Indépendance

34

□ A et B sont indépendants ssi:

$$P(A|B) = P(A) \text{ ou } P(B|A) = P(B) \text{ ou } P(A, B) = P(A)P(B)$$



$$P(\text{MalDeDent}, \text{Prise}, \text{Carie}, \text{Température}) \\ = P(\text{MalDeDent}, \text{Prise}, \text{Carie})P(\text{Température})$$

Exercice indépendance

35

$p(\text{intelligent} \wedge \text{étudie} \wedge \text{préparé})$	intelligent		\neg intelligent	
	étudie	\neg étudie	étudie	\neg étudie
préparé	.432	.16	.084	.008
\neg préparé	.048	.16	.036	.072

- Q1: Est-ce que *intelligent* est indépendant de *étudie*?
- Q2: Est-ce que *préparé* est indépendant de *étudie*?

Indépendance

36

- 32 entrées réduites à 12 (8+4)
- Pour n lancer d'une pièce de monnaie: 2^n entrées, représentable en $2n$
- Indépendance absolue!!!
 - ▣ Puissante mais rare
- La dentisterie est un domaine complexe avec des centaines de variables
 - ▣ Aucune n'est indépendante
 - ▣ Quoi faire?

Indépendance conditionnelle

37

- $P(\text{MalDeDent}, \text{Carie}, \text{Prise})$ a $2^3 - 1 = 7$ entrées indépendantes
- Si j'ai une carie, la probabilité que le crochet reste pris ne dépend pas de si j'ai un MalDeDent
$$(1) P(\text{prise} | \text{maldedent}, \text{carie}) = P(\text{prise} | \text{carie})$$
- La même indépendance tient si je n'ai pas de carie
$$(2) P(\text{prise} | \text{maldedent}, \neg \text{carie}) = P(\text{prise} | \neg \text{carie})$$
- Prise est conditionnellement indépendant de MalDeDent si carie
$$P(\text{Prise} | \text{MalDeDent}, \text{carie}) = P(\text{Prise} | \text{carie})$$
- Équivalents:
$$P(\text{MalDeDent} | \text{Prise}, \text{carie}) = P(\text{MalDeDent} | \text{carie})$$
$$P(\text{MalDeDent}, \text{Prise} | \text{carie}) = P(\text{MalDeDent} | \text{carie}) P(\text{Prise} | \text{carie})$$

Indépendance conditionnelle

38

- Pour écrire la distribution complète, utilisons la règle de chaînage

$$\begin{aligned} &P(\text{MalDeDent}, \text{Prise}, \text{Carie}) \\ &= P(\text{MalDeDent} | \text{Prise}, \text{Carie}) P(\text{Prise}, \text{Carie}) \\ &= P(\text{MalDeDent} | \text{Prise}, \text{Carie}) P(\text{Prise} | \text{Carie}) P(\text{Carie}) \\ &= \mathbf{P(\text{MalDeDent} | \text{Carie})} P(\text{Prise}, | \text{Carie}) P(\text{Carie}) \end{aligned}$$

- l.e.: $2+2+1 = 5$ valeurs indépendantes
- La plupart du temps, l'utilisation de **l'indépendance conditionnelle** réduit la taille de la représentation de la distribution conjointe d'exponentielle en n à linéaire en n
- **L'indépendance conditionnelle est la plus simple et plus robuste forme de connaissances à propos des environnements incertains**

39

Règle de Bayes

Règle de Bayes

40

□ Règle du produit: $P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$

■ Règle de Bayes: $P(a|b) = \frac{P(b|a)P(a)}{P(b)}$

□ Ou sous la forme distribution:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)} = \alpha P(X|Y)P(Y)$$

Règle de Bayes

41

- Elle est utile pour évaluer la probabilité diagnostique d'une probabilité causale:

$$P(Cause|Effet) = \frac{P(Effet|Cause)P(Cause)}{P(Effet)}$$

- E.g.: Supposons M, la méningite et S avoir le cou raide:

$$P(s|m) = 0.8 \quad P(s) = 0.1 \quad P(m) = .0001$$

$$P(m|s) = \frac{P(s|m)P(m)}{P(s)} = \frac{0.8 * 0.0001}{0.1} = 0.0008$$

- Note: La probabilité d'avoir la méningite à posteriori est encore très petite!

Naive Bayes Classifier

42



- Base de connaissances:
 - ▣ Évidences: E_1, \dots, E_m
 - ▣ Hypothèses: H_1, \dots, H_n
 - ▣ E_i, H_j sont binaires
 - ▣ Les hypothèses sont mutuellement exclusives (pas d'overlap)
 - ▣ Elles sont exhaustives (couvre tous les cas possibles)
- Cas (cases): évidences pour une instance particulière (E_1, \dots, E_k)
- But: Trouver l'hypothèse H_i avec la plus haute probabilité à postériori
 - ▣ $\text{Max}_i P(H_i | E_1, \dots, E_k)$

Naive Bayes Classifier

43

$$\begin{aligned} &P(\text{Carie} | \text{maldedent} \wedge \text{prise}) \\ &= \alpha P(\text{maldedent} \wedge \text{prise} | \text{Carie}) P(\text{Carie}) \\ &= \alpha P(\text{maldedent} | \text{Carie}) P(\text{prise} | \text{Carie}) P(\text{Carie}) \end{aligned}$$

$$P(\text{Cause}, \text{Effet}_1, \dots, \text{Effet}_n) = P(\text{Cause}) \prod_i P(\text{Effet}_i | \text{Cause})$$



- Le nombre total de paramètres est linéaire en n

44

Monde de la forêt enchantée

Monde de la forêt enchantée

45

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 V OK	2,2	3,2	4,2
1,1 OK	2,1 V OK	3,1	4,1

- $C_{ij} = \text{Vrai}$ ssi $[i,j]$ contient une crevasse
- $V_{ij} = \text{Vrai}$ ssi $[i,j]$ est venteuse
- Inclut uniquement $V_{1,1}, V_{1,2}, V_{2,1}$ dans le modèle de probabilités

Spécification du modèle probabiliste

46

- La distribution conjointe complète est $P(C_{1,1}, \dots, C_{4,4}, V_{1,1}, V_{1,2}, V_{2,1})$
- Appliquons la règle du produit:
 $P(V_{1,1}, V_{1,2}, V_{2,1} | C_{1,1}, \dots, C_{4,4}) P(C_{1,1}, \dots, C_{4,4})$
 - ▣ (Pour obtenir un $P(Effet|Cause)$)
- Premier terme: 1 si crevasse adjacente à case venteuse, 0 sinon
- Second terme: Les crevasses sont placées aléatoirement avec probabilité de 0.2 par case:

$$P(C_{1,1}, \dots, C_{4,4}) = \prod_{i,j=1,1}^{4,4} P(C_{i,j}) = 0.2^n \times 0.8^{16-n}$$

- Pour n crevasses

Observations et requêtes

47

- Nous savons que:


$$v = \neg v_{1,1} \wedge v_{1,2} \wedge v_{2,1}$$
$$connue = \neg c_{1,1} \wedge \neg c_{1,2} \wedge \neg c_{2,1}$$

- La requête est $P(c_{1,3} | connue, v)$
- Définissons $Inconnue = C_{i,j} \notin Connue \cup C_{1,3}$
- Pour l'inférence par énumération nous avons
$$P(C_{1,3} | connue, v)$$
$$= \alpha \sum_{inconnue} P(C_{1,3}, inconnue, connue, v)$$
- Exponentiel avec le nombre de tuiles!

En utilisant l'indépendance conditionnelle

48

- Intuition: les observations sont conditionnellement indépendantes des autres tuiles étant donné les tuiles voisines cachées



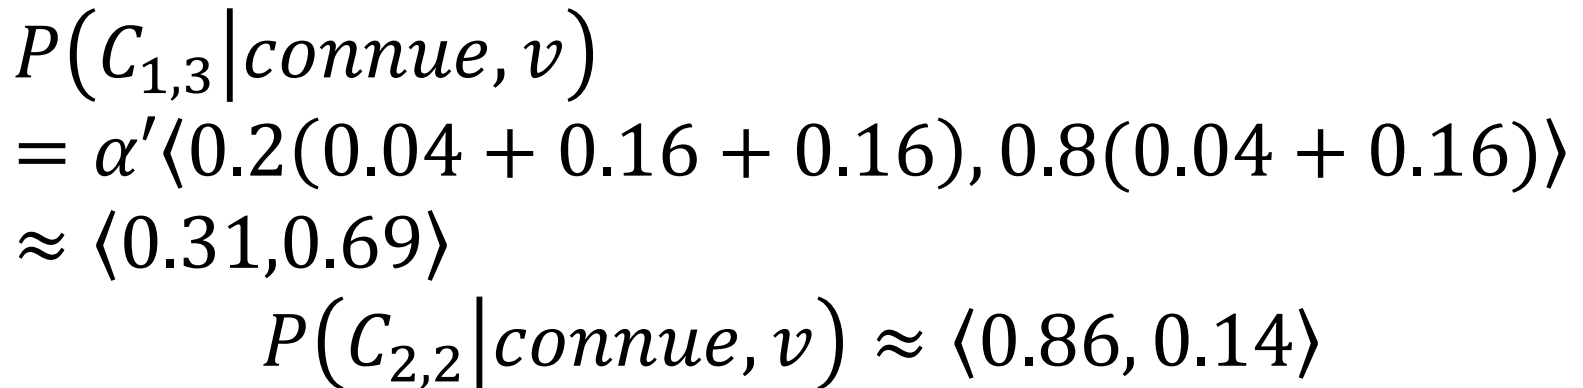
- Définissons $Inconnue = Frontière \cup Autre$
 $P(v|C_{1,3}, Connue, Inconnue) = P(v|C_{1,3}, Connue, Frontière)$
- Manipulons la requête dans une forme qui nous permettra d'utiliser ceci!

En utilisant l'indépendance conditionnelle

49

$$\begin{aligned} P(C_{1,3} | \text{connue}, v) &= \alpha \sum_{\text{inconnue}} P(C_{1,3}, \text{inconnue}, \text{connue}, v) \\ &= \alpha \sum_{\text{inconnue}} P(v | \text{connue}, C_{1,3}, \text{inconnue}) P(C_{1,3}, \text{connue}, \text{inconnue}) \\ &= \alpha \sum_{\text{Frontière}} \sum_{\text{Autre}} P(v | \text{connue}, \text{frontière}, \text{autre}) P(C_{1,3}, \text{connue}, \text{frontière}, \text{autre}) \\ &= \alpha \sum_{\text{Frontière}} \sum_{\text{Autre}} P(v | \text{connue}, \text{frontière}) P(C_{1,3}, \text{connue}, \text{frontière}, \text{autre}) \\ &= \alpha \sum_{\text{Frontière}} P(v | \text{connue}, C_{1,3}, \text{frontière}) \sum_{\text{Autre}} P(C_{1,3}, \text{connue}, \text{frontière}, \text{autre}) \\ &= \alpha \sum_{\text{Frontière}} P(v | \text{connue}, C_{1,3}, \text{frontière}) \sum_{\text{Autre}} P(C_{1,3}) P(\text{connue}) P(\text{frontière}) P(\text{autre}) \\ &= \alpha P(\text{connue}) P(C_{1,3}) \sum_{\text{Frontière}} P(v | \text{connue}, C_{1,3}, \text{frontière}) P(\text{frontière}) \end{aligned}$$

50



51

Raisonnement probabiliste

Réseau Bayésien

52

- Un réseau Bayésien est un modèle de représentation de connaissances qui se traduit par un **graphe orienté acyclique**
- Les nœuds y correspondent à des **variables aléatoires**, et les arcs à des **influences** de nature **causale** ou **conditionnelle**
- Dans cette structure, on émet l'hypothèse que **les connaissances disponibles** permettent de définir, sur l'ensemble des variables aléatoires, une mesure de probabilité unique

Définition formel d'un réseau bayésien

53

- Formellement, un réseau bayésien est constitué de quatre principaux éléments
- 1. Un ensemble V de **variables aléatoires** constituant les noeuds du réseau
- 2. Un ensemble de relations $r \in R$, où $r \subseteq V \times V$
 - ▣ Ces relations sont dirigées
 - ▣ $r(v_1, v_2)$ définit un arc partant du noeud v_1 et allant vers le noeud v_2

Définition formel d'un réseau bayésien

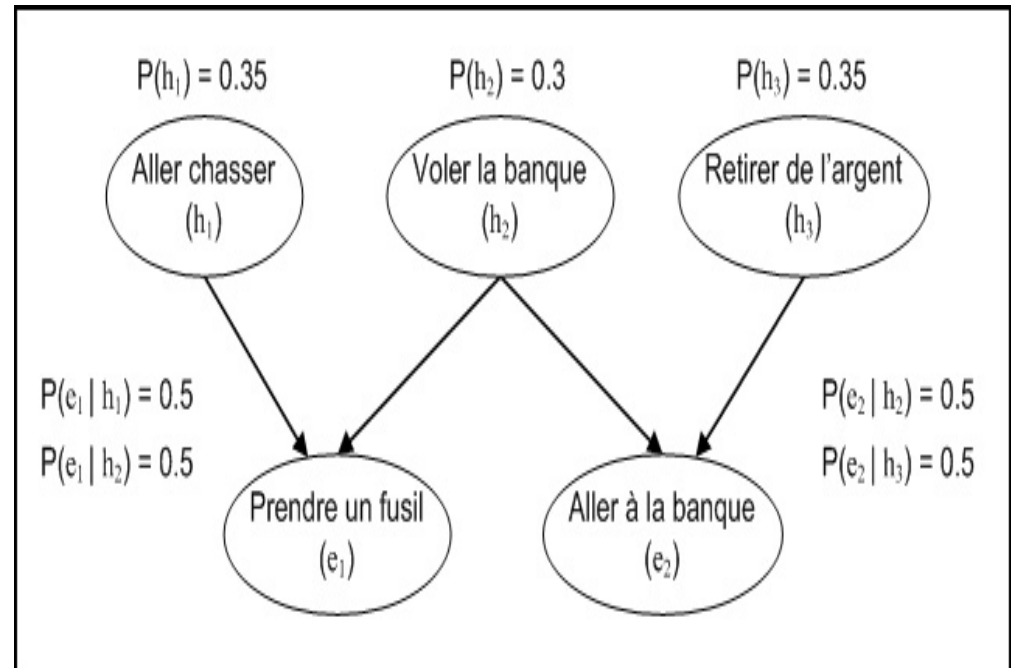
54

3. Une table *TPI* décrivant la probabilité initiale des nœuds racines
 - ▣ C'est l'ensemble des **noeuds parents** n'étant influencés par aucun autre nœud
 - ▣ Ces nœuds possèdent seulement des arcs descendants (des arcs allant de ces nœuds vers d'autres)
4. Une table *TPC* décrivant la probabilité conditionnelle des nœuds non-racines
 - ▣ C'est-à-dire les **noeuds enfants** étant influencés par au moins un autre noeud et possédant un ou plusieurs arcs ascendants (des arcs partant d'un autre noeud et allant vers celui-ci)

Exemple de reconnaissance d'AVQ

55

- Dans cet exemple, chacun des plans automatisés de la hiérarchie est représenté par un noeud racine spécifiant une hypothèse de haut niveau
- L'ensemble des hypothèses possibles pour la reconnaissance est formé de $H = \{h_1, h_2, h_3\}$



- Une **probabilité initiale** est attribuée à chacune de ces hypothèses, soit
- $P(h_1) = 0.35$, $P(h_2) = 0.3$ et $P(h_3) = 0.35$.

Encoder la librairie avec un réseau bayésien

56

- Les nœuds non-racines représentent des actions de bas niveau qui influenceront (conditionnent) la probabilité des hypothèses de haut niveau
- On note ici que toutes ces hypothèses de haut niveau sont considérées **mutuellement indépendantes et disjointes**
 - La somme des probabilités est donc égale à 1

Définir la reconnaissance en termes de processus de décision bayésien

57

- En démarrant d'une librairie de plans représentée sous forme d'un réseau bayésien, il est possible de définir l'activité de reconnaissance de plans en termes de **processus de décision bayésien**
- Pour ce faire, on doit d'abord admettre trois postulats de départ:
 1. Les hypothèses h_i sont mutuellement exclusives (**disjointes**)
 2. Elles sont **exhaustives** (la librairie de plans est complète)
 3. Il y a une indépendance conditionnelle des observations par rapport aux hypothèses
- Ces postulats sont nécessaires à l'application du théorème de Bayes dans le processus de décision

Définir la reconnaissance en termes de processus de décision bayésien

58

- Un processus de décision bayésien prend en entrée une ou plusieurs **observations**
- Ces observations doivent nécessairement correspondre à des noeuds **non-racines** du réseau
 - ▣ Des actions basiques

Définir la reconnaissance en termes de processus de décision bayésien

59

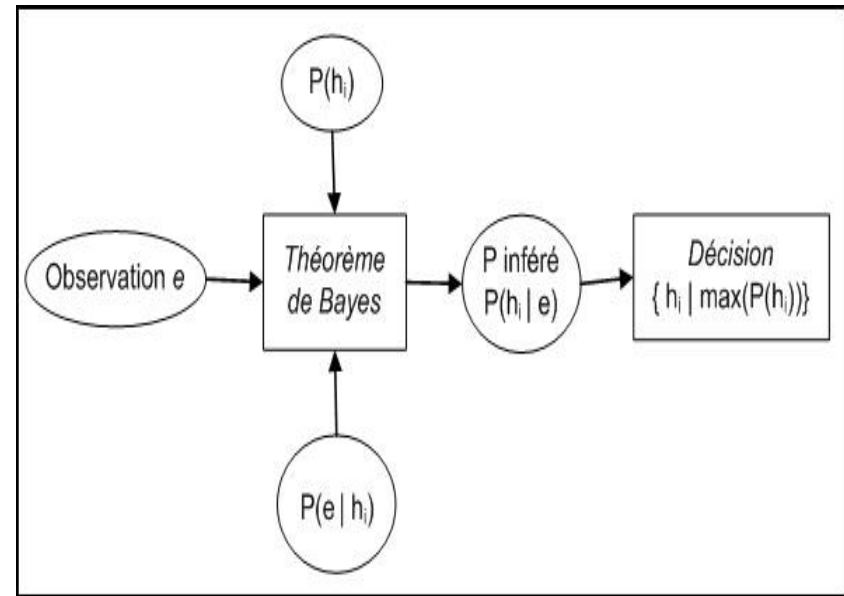
- Par la suite, on se base sur la **probabilité initiale** $P(h_i)$ attribuée à chacune des hypothèses de plans possibles
- Ainsi que sur la **probabilité conditionnelle** $P(e | h_i)$ attribuée à chacune des observations moyennant une hypothèse
- Le processus de reconnaissance consiste à **réviser la distribution des probabilités** à travers les hypothèses du réseau en appliquant le théorème de Bayes

Définir la reconnaissance en termes de processus de décision bayésien

60

$$P(h_i | e_1 \wedge \dots \wedge e_m) = \frac{P(e_1 | h_i) * P(e_m | h_i) * P(h_i)}{\sum_{j=[1,n]} P(e_1 | h_j) * \dots * P(e_m | h_j) * P(h_j)}$$

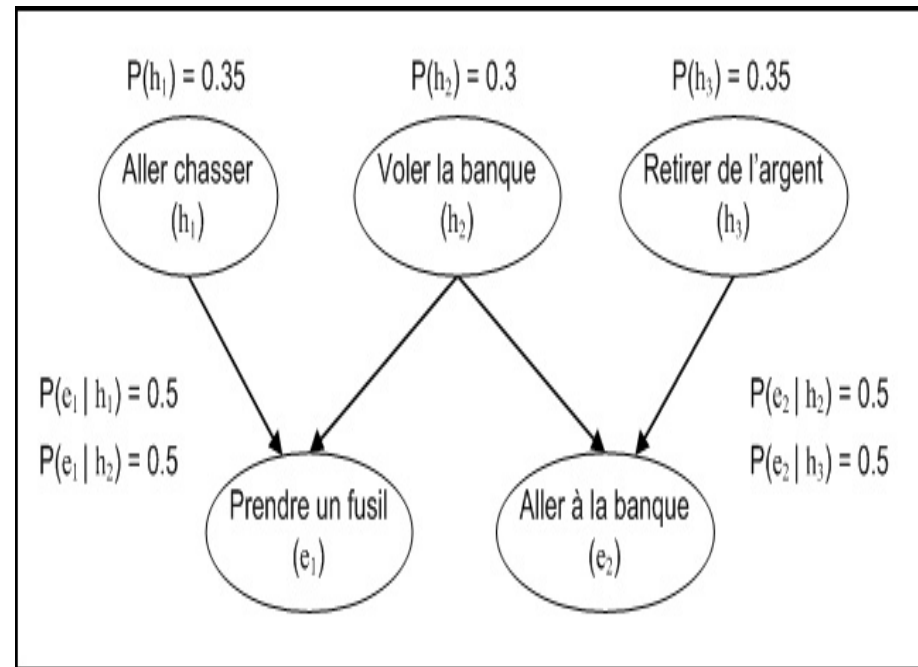
- Où m correspond au nombre d'observations recueillies jusqu'à maintenant
- Et n au nombre d'hypothèses de haut niveau du réseau
- En d'autres termes, on cherche le **plan** h_i possédant la **probabilité maximale** $\max(P(h_i))$, pour $i = 1$ à n .



Exemple applicatif de l'approche bayésienne

61

- Dans cette librairie, trois hypothèses de plans possibles sont en compétition



- Soit les plans *Aller chasser*, *Voler la banque* et *Retirer de l'argent*, représentés respectivement par h_1 , h_2 et h_3 .

Exemple applicatif de l'approche bayésienne

62

- La probabilité initiale attribuée aux plans $h1$ et $h3$ est légèrement **plus élevée** (0.35) que celle attribuée à $h2$ (0.3)
- Ces deux plans sont légèrement priorisés au départ par rapport à $h2$
- On peut supposer ici que cette priorité tient compte du fait que la personne observée a plus de chances d'effectuer une activité honnête qu'une activité criminelle
- On note que la **distribution probabiliste est uniforme**, et donc $P(h1) + P(h2) + P(h3) = 1$
- Elle devra demeurer uniforme après chaque cycle d'inférence

Exemple applicatif de l'approche bayésienne

63

- L'agent observe l'action e_1
- Le système devra effectuer la révision de la probabilité de chacune des hypothèses, suivant le modèle de raisonnement bayésien
- Il doit d'abord estimer la probabilité révisée de la **première hypothèse** h_1

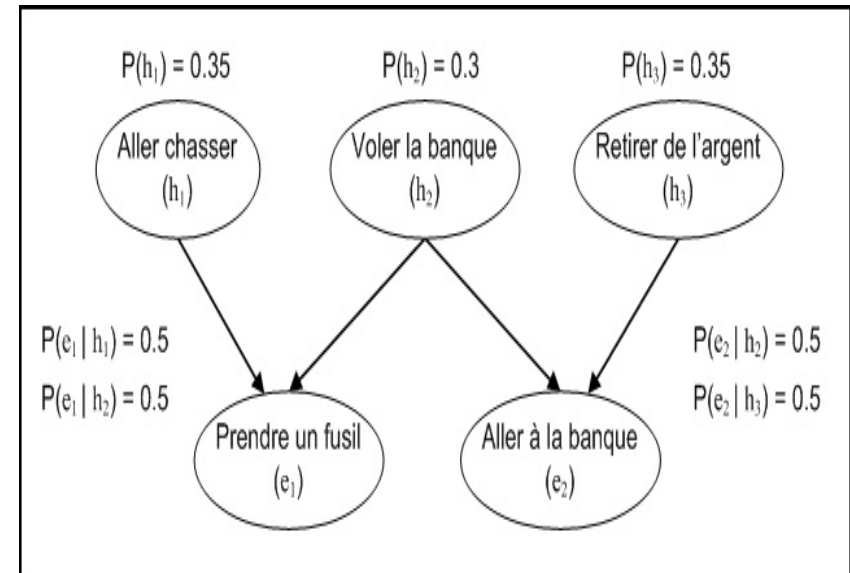
$$P(h_1 | e_1) = \frac{P(e_1 | h_1) * P(h_1)}{(P(e_1 | h_1) * P(h_1)) + (P(e_1 | h_2) * P(h_2)) + (P(e_1 | h_3) * P(h_3))}$$

$$P(h_1 | e_1) = \frac{0.5 * 0.35}{(0.5 * 0.35) + (0.5 * 0.3) + (0 * 0.35)}$$

$$P(h_1 | e_1) = \frac{0.175}{0.325}$$

$$P(h_1 | e_1) = 0.54$$

Nouvelle probabilité de h_1
Après le cycle d'inférence.



Exemple applicatif de l'approche bayésienne

64

- Maintenant, calculons la nouvelle probabilité de l'hypothèse h_2
- L'estimation de $P(h_2 | e_1) = (0.5 * 0.3) / ((0.5 * 0.35) + (0.5 * 0.3) + (0 * 0.35))$ correspond à 0.46, soit 46%
- Cette probabilité est **inférieure** à celle attribuée à la première hypothèse h_1
- Pourtant, la probabilité conditionnelle de l'observation par rapport aux hypothèses h_1 et h_2 est équivalente, soit 0.5 dans les deux cas
- La différence entre les deux nouvelles probabilités estimées est alors attribuable à la **probabilité initiale** des deux hypothèses
 - ▣ Cependant, on note que l'observation e_1 renforce néanmoins la crédibilité de l'hypothèse h_2

Exemple applicatif de l'approche bayésienne

65

- Finalement, la probabilité de l'hypothèse h_3 , soit $P(h_3 | e_1) = (0 * 0.3) / ((0.5 * 0.35) + (0.5 * 0.3) + (0 * 0.35))$ est égale à 0
- La raison est qu'il n'existe **aucune relation causale** entre l'observation e_1 et l'hypothèse h_3
- Ça signifie que cette observation ne peut pas avoir été causée par la réalisation du plan h_3
- Le résultat du processus de reconnaissance correspond donc à l'hypothèse la plus probable h_1
 - soit le plan ***Aller chasser.***

Exemple applicatif de l'approche bayésienne

66

2^{ème} observation : révision de l'hypothèse h_1

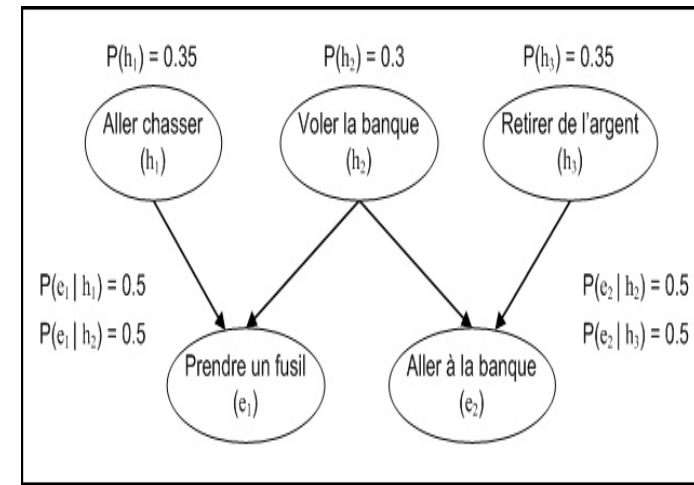
- Supposons maintenant l'arrivée d'une deuxième observation e_2
 - ▣ Soit l'action de bas niveau **Aller à la banque**
- Le processus de reconnaissance reprend depuis le début
- On estime la probabilité de chacune des hypothèses en fonction des deux observations conjointes e_1 et e_2
- Pour la première hypothèse :

$$P(h_1 | e_1 \wedge e_2) = \frac{P(e_1 | h_1) * P(e_2 | h_1) * P(h_1)}{\sum_{j=[1,3]} (P(e_1 | h_j) * P(e_2 | h_j) * P(h_j))}$$

$$P(h_1 | e_1 \wedge e_2) = \frac{0.5 * 0 * 0.35}{(0.5 * 0 * 0.35) + (0.5 * 0.5 * 0.3) + (0 * 0.5 * 0.35)}$$

$$P(h_1 | e_1 \wedge e_2) = \frac{0}{0.075}$$

$$P(h_1 | e_1 \wedge e_2) = 0$$



Exemple applicatif de l'approche bayésienne

67

- La probabilité de l'hypothèse h_1 est réévaluée à 0
- La raison est qu'on suppose que les observations sont reliées à un seul et même plan
- Il n'existe aucune relation de causalité entre l'hypothèse h_1 et l'observation e_2
- Ce plan ne peut donc pas être à la fois la cause de l'observation e_1 et e_2

Exemple applicatif de l'approche bayésienne

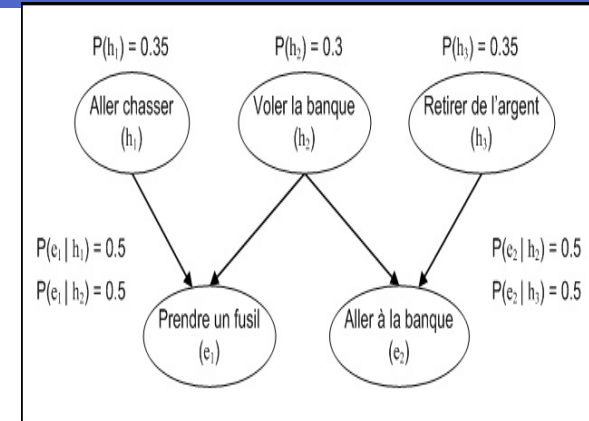
68

- Le calcul de la probabilité de l'hypothèse h_3 donnera alors le même résultat
- Celle-ci ne permet pas d'expliquer la première observation e_1
- Calculons alors la nouvelle probabilité estimée de l'hypothèse h_2
- Celle-ci devrait logiquement récolter 100% de la distribution probabiliste

Exemple applicatif de l'approche bayésienne

69

$$P(h_2 | e_1 \wedge e_2) = \frac{P(e_1 | h_2) * P(e_2 | h_2) * P(h_2)}{\sum_{j=[1,3]} (P(e_1 | h_j) * P(e_2 | h_j) * P(h_j))}$$
$$P(h_2 | e_1 \wedge e_2) = \frac{0.5 * 0.5 * 0.35}{(0.5 * 0 * 0.35) + (0.5 * 0.5 * 0.3) + (0 * 0.5 * 0.35)}$$
$$P(h_2 | e_1 \wedge e_2) = \frac{0.075}{0.075}$$
$$P(h_2 | e_1 \wedge e_2) = 1$$



- La seule hypothèse pouvant expliquer à la fois l'observation e_1 et e_2 est h_2
- On note que cette distribution est toujours uniforme ($P(h_1) = 0$) + ($P(h_2) = 1$) + ($P(h_3) = 0$) = 1
- Le résultat du processus de reconnaissance serait le plan h_2 : ***Voler la banque***

Sommaire

70

- Les probabilités constituent un formalisme rigoureux pour le raisonnement incertain
- Les distributions de probabilités conjointes spécifient la probabilité de chaque événement atomique
- Les requêtes peuvent être répondues par la somme des événements atomiques
- Pour les domaines non triviaux, il faut réduire la taille de la distribution conjointe
- L'indépendance et l'indépendance conditionnelle servent d'outils à cette fin